Sistema Ibrido per lo Screening dell'Autismo basato su Machine Learning e Ontologie

Membri:

Cognome e nome: Storelli Leonardo, Matricola:758472

Link GitHub: https://github.com/GongoTheBongo/Progetto-ICON-a.a-23-24.git

A.A: 2023/2024

Indice:

1. INTRODUZIONE 3

2. IL DATASET E ANALISI ESPLORATIVA 4

2.1 Descrizione dei Dati 4

2.2 Analisi Grafica 5

3. ONTOLOGIA E RAPPRESENTAZIONE SEMANTICA DEL DOMINIO.....6

3.1 Analisi del Dominio 6

3.1.1 Classi 7

3.1.2 Object property 7

3.1.3 Data property 7

3.1.4 Individuals (Istanze): 8

3.2 Software per la realizzazione dell'Ontologia: 9

3.3 QUERY 9

3.3.1 DL Query 9

3.3.2 Interrogazione tramite libreria OwlReady2 9

4. APPRENDIMENTO SUPERVISIONATO: ANALISI DEGLI ALGORITMI 10

4.1 Scelte di progetto 10

4.2 Metriche di valutazione 11

4.3 K-Nearest Neighbors (KNN) 12

4.3.1 Decisioni di progetto 12

4.3.2 Ottimizzazione degli iperparametri (GridSearchCV) 12

4.3.3 Addestramento e predizione 13

4.3.4 Valutazione Finale 13

4.4 Random Forest (RF) e Feature Importance 15

4.4.1 Decisioni di progetto 15

4.4.2 Ottimizzazione degli iperparametri (GridSearchCV) 16

4.4.3 Valutazione Finale 16

4.5 Support Vector Machine (SVM) 19

4.5.1 Decisioni di progetto 19

4.5.2 Ottimizzazione degli iperparametri (GridSearchCV) 19

4.5.3 Valutazione Finale 20

5. APPRENDIMENTO NON SUPERVISIONATO (CLUSTERING).....22

5.1 Fuzzy C Means 22

6. Risultati 24
6.1 Dataset Originale 24
6.2 Dataset dei Fattori 24
7. ANALISI RISULTATI E CONCLUSIONI 24
7.1 Analisi del Dataset Originale 25
7.2 Analisi del Dataset dei Fattori (Fuzzy C-Means) 25
7.3 Conclusioni 26

1. INTRODUZIONE

Questo progetto nasce con l'obiettivo di supportare lo screening preliminare per la diagnosi del Disturbo dello Spettro Autistico (ASD) attraverso l'analisi di un dataset di indicatori comportamentali e demografici. Per affrontare la complessità dei dati, l'approccio analitico ha integrato sia metodologie di apprendimento non supervisionato — per raggruppare le caratteristiche in fattori latenti e comprendere le relazioni nascoste — sia algoritmi di apprendimento supervisionato, ottimizzati rigorosamente per garantire un'elevata precisione predittiva. Inoltre, lo studio è fondato sullo sviluppo di un'ontologia di riferimento, uno strumento essenziale per strutturare in modo rigoroso e formale la conoscenza del dominio clinico oggetto di indagine.

Il Disturbo dello Spettro Autistico è una condizione complessa del neurosviluppo. Sfortunatamente, i percorsi clinici tradizionali per ottenere una diagnosi formale comportano spesso tempi di attesa prolungati, procedure complesse e costi elevati. Il crescente numero di casi a livello globale e il conseguente impatto socio-economico evidenziano l'urgente

necessità di sviluppare strumenti di pre-valutazione che siano rapidi, efficaci e facilmente accessibili. Pertanto, l'implementazione di modelli di Machine Learning capaci di uno screening efficiente e affidabile rappresenta un passo fondamentale: non per sostituire il giudizio medico, ma per fornire un solido supporto decisionale agli operatori sanitari, aiutandoli a identificare tempestivamente le persone che dovrebbero essere indirizzate verso un iter diagnostico clinico completo.

2. IL DATASET E ANALISI ESPLORATIVA

Il dataset utilizzato per questo progetto, tratto dal repository *UCI Machine Learning* (www.archive.ics.uci.edu), raccoglie dati relativi allo screening dell'autismo su diverse fasce d'età, comprendendo bambini, adolescenti e adulti. Questo set di dati contiene caratteristiche influenti che abbiamo preparato e utilizzato per le nostre analisi, con l'obiettivo specifico di determinare i tratti autistici e ottimizzare la classificazione dei casi di ASD.

Al suo interno sono registrate dieci caratteristiche comportamentali principali, affiancate da ulteriori attributi individuali (come dati anagrafici e fattori clinici). Nelle scienze del comportamento, questo insieme di variabili si è già dimostrato ampiamente efficace nel distinguere i casi positivi di ASD dai soggetti di controllo, fornendoci così una base empirica solida e attendibile per l'addestramento e la valutazione dei nostri modelli predittivi.

2.1 Descrizione dei Dati

Questo dataset raccoglie i dati di screening relativi a un campione di pazienti sottoposti a un test valutativo strutturato. Nello specifico, i dati registrano dieci caratteristiche comportamentali (valutate tramite domande a risposta binaria), affiancate da ulteriori dati demografici (come età, genere, etnia e paese di residenza) e informazioni sulla storia clinica dell'individuo, tra cui eventuali casi di ittero neonatale o familiarità genetica. Insieme, queste caratteristiche individuali si sono dimostrate efficaci nella scienza del comportamento per rilevare i tratti autistici e predire la variabile target, ovvero la diagnosi finale.

Per garantire che i modelli di apprendimento automatico potessero elaborare correttamente le informazioni, è stata eseguita una rigorosa fase di pulizia e pre-elaborazione. Inizialmente, le variabili categoriche sono state trasformate in un formato idoneo tramite la tecnica del

One-Hot Encoding. Particolare attenzione è stata dedicata alla gestione dei dati mancanti (Missing Values): per le features continue, i valori nulli sono stati sostituiti con la moda della rispettiva colonna. Questa strategia di imputazione ha permesso di preservare la distribuzione statistica generale dei dati, minimizzando la perdita di informazioni utili. Al contrario, per quanto riguarda la variabile target, le righe prive di diagnosi o con etichette non valide sono state rimosse dal dataset, assicurando così valori binari puliti e idonei per un corretto addestramento supervisionato.

Un aspetto critico affrontato durante la preparazione dei dati è stato lo sbilanciamento delle classi, tipico dei dataset clinici. Per impedire che i modelli sviluppassero un bias verso la classe maggioritaria, è stata adottata la tecnica di sovracampionamento SMOTE (*Synthetic Minority Over-sampling Technique*), che bilancia il dataset generando sinteticamente nuovi campioni per la classe minoritaria basandosi sulle similarità delle caratteristiche.

Per garantire l'assoluta validità dei risultati ed evitare il fenomeno del *data leakage*, la separazione in set di addestramento e di test è avvenuta rigorosamente prima di qualsiasi bilanciamento. Inoltre, lo SMOTE è stato integrato all'interno di un'apposita *Pipeline*: in questo modo i campioni artificiali sono stati generati esclusivamente sui dati di training durante le iterazioni della cross-validation, permettendo una valutazione finale su un test set composto unicamente da dati reali e mai visti dai modelli.

2.2 Analisi Grafica

Per comprendere meglio le dinamiche interne al dataset prima dell'addestramento dei modelli, è stata condotta un'analisi esplorativa sulle dieci caratteristiche comportamentali principali. Il grafico a barre illustra il confronto diretto tra le medie delle risposte fornite dai soggetti con diagnosi di autismo (in arancione) e il gruppo di controllo (in azzurro).

Dal grafico emerge una tendenza netta: il gruppo con diagnosi positiva (is_autistic = 1) registra sistematicamente punteggi medi superiori in quasi tutte le domande. Le differenze più marcate, che suggeriscono un maggiore potere discriminante ai fini della classificazione, si osservano in corrispondenza delle feature **A4_Score** (0.69 contro 0.53) e **A9_Score** (0.67 contro 0.46). Al contrario, la domanda **A8_Score** rappresenta un'eccezione, mostrando un punteggio medio identico (0.62) per entrambi i gruppi, il che indica una minore rilevanza di questa specifica domanda se analizzata singolarmente

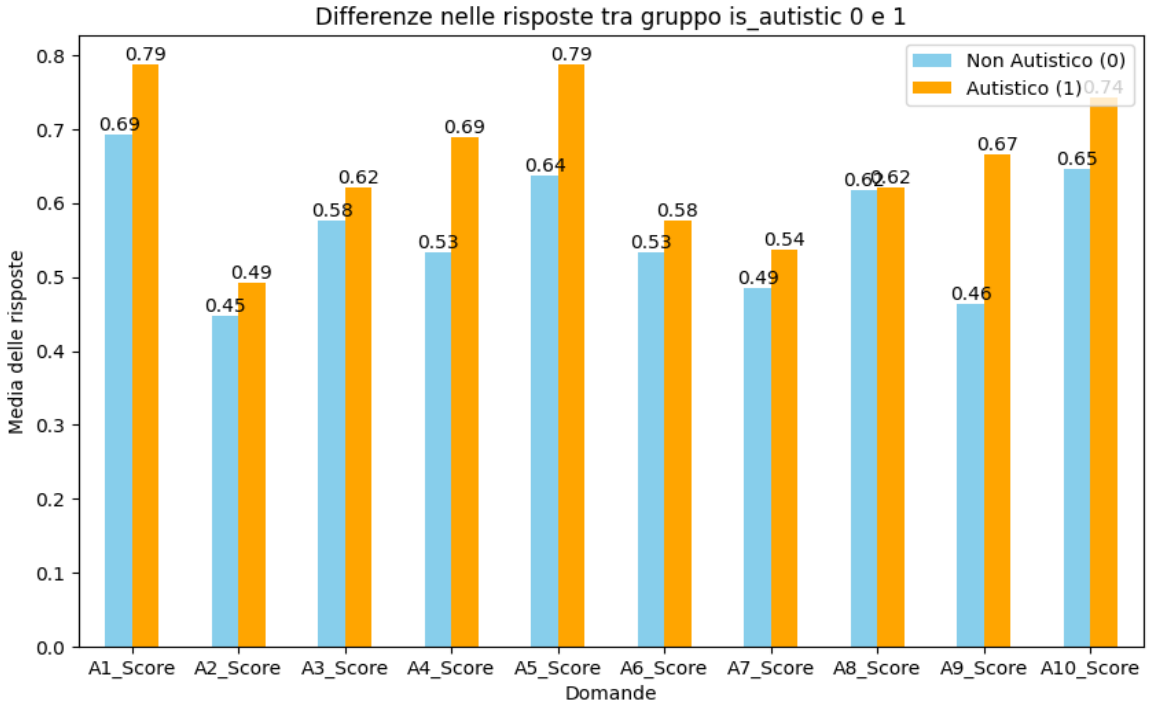

3. ONTOLOGIA E RAPPRESENTAZIONE SEMANTICA DEL DOMINIO

Un'ontologia è un modello di conoscenza che consente di rappresentare in modo univoco le informazioni relative ad un determinato dominio. Durante l'analisi del dominio si indentificano i concetti principali, le relazioni e le proprietà che caratterizzano il dominio. Successivamente questi concetti, relazioni e proprietà possono essere formalizzate mediante un linguaggio di rappresentazione formale come, ad esempio, OWL (Ontology Web Language).

3.1 Analisi del Dominio

Dato il set di dati utilizzato e le informazioni sugli attributi, abbiamo deciso di dividere gli attributi del dataset in:

-" ciò che deve essere rappresentato": gli attributi fondamentali e cruciali che devono essere rappresentati per catturare le informazioni essenziali dal dataset. Nel contesto dell'autismo, include: domande, test e pazienti

-" ciò che caratterizza ciò che deve essere rappresentato": le proprietà delle entità rappresentate, (nel caso del paziente ad esempio possono essere età, sesso...)

-" ciò che può essere ricavato": ad esempio gli attributi 'Screening Score' e 'Used the screening app before'

-" ciò che può essere scartato": ad esempio l'attributo 'Country of residence'.

3.1.1 Classi

Analizzando il dominio abbiamo deciso di rappresentare come classi dell'ontologia:

- **Paziente**: La classe Paziente, rappresenta l'insieme dei pazienti sottoposti al test. A questa classe abbiamo associato diverse proprietà: -
    - Age: rappresenta l'età del paziente al momento del test.
    - Gender: rappresenta il genere del paziente.
    - isAutistic: vera se paziente è stata già riscontrata una forma di autismo.
    - Ittero: vera se il paziente è nato con una forma di ittero.
    - PDDparent: vera se una parente stretto del paziente presenta forme di PDD.
    - Etnia: rappresenta l'etnia del paziente.
    - IdPaziente: rappresenta il paziente in modo univoco.
- **Test**: La classe Test, rappresenta l'insieme dei test svolti da tutti i pazienti. A questa classe sono associati tre proprietà:
    - CompilatoreTest: rappresenta chi ha compilato svolto il test con il paziente
    - IdTest: identifica univocamente un test
- **Domanda**: rappresenta la classe delle domande svolte. Abbiamo associato a questa classe due proprietà:
    - Risposta: vera se è vera la risposta del test.
    - NumQuestion: numero della domanda all'interno del test.

3.1.2 Object property

Una object property permette di mettere in relazione due individui, siano essi di classi distinte o della stessa classe. Tra le classi abbiamo definito delle relazioni che rappresentano come queste interagiscono tra di loro. Le relazioni definite sono:

- haTest (Paziente) -> Test: permette di individuare i test svolti da un paziente.
- has_Question (Test) ->Domanda: permette di individuare le risposte date dal paziente. Informazioni come 'Screening Score' e 'Used the screening app before' possono essere derivate dall'ontologia realizzata con semplici query in SPARQL.

3.1.3 Data property

Una data property permette di mettere in relazione un individuo (ovvero un'istanza specifica di una classe) con un valore di tipo primitivo, come ad esempio un numero intero, una stringa di testo o un valore logico booleano (vero/falso). Nel contesto della nostra ontologia, le data property sono lo strumento tecnico che ci ha permesso di tradurre le caratteristiche anagrafiche, cliniche e comportamentali presenti nel dataset originale in attributi concreti e interrogabili.

Mentre le *object property* collegano le classi tra loro (come un paziente al suo test), le *data property* descrivono le proprietà intrinseche della singola entità. Nello specifico del nostro dominio, abbiamo implementato data property mirate per ciascuna classe:

- **Per la classe Paziente:** sono state definite data property anagrafiche come Age (associata a un valore numerico intero), Gender ed Etnia (associate a stringhe di testo). A queste si aggiungono le data property cliniche fondamentali, modellate tipicamente come valori booleani, tra cui isAutistic, Ittero e PDDparent, che indicano la presenza o l'assenza della relativa condizione medica o genetica.
- **Per la classe Domanda:** sono state definite data property per tracciare la struttura del questionario, come NumQuestion (un valore intero che rappresenta l'ordine della domanda) e Risposta (un valore booleano o intero che ne registra l'esito binario).
- **Per la classe Test:** sono stati definiti attributi identificativi come IdTest e descrittivi come CompilatoreTest (stringa che indica chi ha assistito il paziente).

L'uso rigoroso dei tipi primitivi per queste proprietà è ciò che rende poi possibile, in fase di programmazione, effettuare query precise (come, ad esempio, filtrare tutti i pazienti in cui la data property isAutistic è strettamente uguale a True, o in cui Age è maggiore di 12).

3.1.4 Individuals (Istanze):

Per alcune entità si sono create delle istanze (o *individuals*), ovvero rappresentazioni concrete e specifiche dei concetti astratti definiti dalle classi. Ad esempio, si sono create istanze specifiche di pazienti a cui attribuire un test e con cui definire le relative relazioni. Nel contesto del nostro progetto, gli individui inseriti nella nostra ontologia derivano direttamente dai record presenti nel file *Autism-Dataset.csv*.

Nello specifico, il processo di "popolamento" (instanziazione) dell'ontologia ha previsto la creazione di:

- **Istanze della classe Paziente:** Ogni riga del dataset corrisponde a un singolo individuo nella classe Paziente (es. *Paziente_1*, *Paziente_2*, ecc.). A ciascuna di queste istanze sono stati assegnati i valori reali estratti dal set di dati tramite le data property (ad esempio, assegnando all'individuo *Paziente_1* un'età di 26 anni, genere maschile, e il valore *True* per la proprietà isAutistic).
- **Istanze della classe Test:** Rappresentano la seduta di screening specifica per quel paziente (es. *Test_1*). Questo individuo viene agganciato al rispettivo paziente tramite la object property haTest.
- **Istanze della classe Domanda:** Rappresentano le singole risposte comportamentali fornite durante il test (corrispondenti alle colonne da *A1_Score* a *A10_Score* del

dataset). Ciascuna domanda è istanziata e collegata al proprio test di riferimento tramite la relazione has_Question.

Questo passaggio è cruciale: trasformare i dati grezzi in **individui relazionati** è ciò che trasforma un semplice modello teorico in una vera e propria base di conoscenza interrogabile. Proprio grazie alla presenza di queste istanze concrete, lo script Python Query_ontologia.py (tramite la libreria *OwlReady2*) è in grado di navigare il grafo della conoscenza e restituire in output, ad esempio, i nomi esatti degli individui che soddisfano le condizioni richieste, come la lista dei pazienti autistici che hanno effettuato un test.

3.2 Software per la realizzazione dell'Ontologia:

L'ontologia è stata create mediante il software Protege, che è uno strumento per creare e gestire ontologie e che permette di definire concetti, classi e relazioni in ontologie basate su standard come OWL. Per la rappresentazione grafica dell'ontologia è stato usato WebVOWL 1.1.7 (Visual Notation for OWL Ontologies) che è uno strumento online che consente di visualizzare e interagire con ontologie OWL in modo grafico e intuitivo.

3.3 QUERY

Una volta strutturata e popolata l'ontologia con le istanze derivate dal dataset, sono state formulate specifiche query per interrogare la base di conoscenza ed estrarre informazioni cliniche e demografiche rilevanti.

3.3.1 DL Query

Inizialmente, per validare la logica del modello concettuale, è stata formulata un'interrogazione in linguaggio DL (*Description Logics*). Ad esempio, è stata scritta una query per restituire tutti i pazienti con un'età maggiore di 12 anni. Il DL è un linguaggio formale utilizzato principalmente nelle discipline dell'intelligenza artificiale per la modellazione rigorosa e la rappresentazione della conoscenza, e permette ai *reasoner* (motori di ragionamento) di dedurre nuove informazioni dalle regole impostate.

3.3.2 Interrogazione tramite libreria OwlReady2

Per integrare l'ontologia all'interno del flusso di lavoro analitico del progetto, è stato sviluppato lo script Python Query_ontologia.py. Questo file sfrutta le potenzialità della libreria OwlReady2, uno strumento progettato per il caricamento, la manipolazione e il ragionamento su ontologie OWL direttamente in ambiente Python.

L'esecuzione dello script si divide in due fasi operative principali:

- **Esplorazione del modello:** Nella prima parte, il codice carica il file ontologia.owl e ne analizza la struttura. Attraverso appositi metodi iterativi, lo script estrae e stampa a terminale la lista completa delle *classi* definite nel modello, delle *object property*, delle *data property* e, infine, le liste degli individui (istanze) che popolano le classi principali (paziente, test e domanda). Questa fase è cruciale per certificare che l'ambiente Python abbia recepito correttamente la struttura creata su Protégé.
- **Esecuzione delle interrogazioni logiche:** Nella seconda parte, il codice sfrutta il metodo onto.search() per estrarre informazioni specifiche. Nello script sono state implementate due interrogazioni mirate:
    - La prima query restituisce la lista dei pazienti che hanno effettivamente effettuato una valutazione, individuando tutti gli individui della classe paziente che risultano associati all'entità Test tramite la object property haTest.
    - La seconda query affina ulteriormente la ricerca: interrogando la classe paziente e filtrando in base alla data property booleana isAutistic=True, il codice estrae e stampa in modo accurato la lista ristretta dei soli pazienti autistici sottoposti allo screening.

4. APPRENDIMENTO SUPERVISIONATO: ANALISI DEGLI ALGORITMI

L'apprendimento supervisionato è una tecnica di apprendimento automatico che mira a istruire un sistema informatico in modo da consentirgli di elaborare automaticamente previsioni sui valori di uscita di un sistema rispetto ad un input sulla base di una serie di esempi ideali, costituiti da coppie di input e di output, che gli vengono inizialmente forniti.
In questa fase, sono stati confrontati tre algoritmi di classificazione per predire la diagnosi di ASD.

4.1 Scelte di progetto

In questo progetto, l'obiettivo dell'apprendimento supervisionato è risolvere un problema di classificazione, in particolare utilizzando la colonna 'Class/ASD' come variabile target da predire basandosi sulle altre caratteristiche relative ai dati dei pazienti.

Nello specifico, sono stati scelti **3 modelli** implementati tramite la libreria scikit-learn (sklearn), combinata con imbalanced-learn (imblearn) per la gestione dello sbilanciamento dei dati tramite tecnica SMOTE. Al fine di evitare fenomeni di *data leakage*, i modelli sono stati inseriti in apposite Pipeline ed è stata automatizzata la ricerca dei migliori iperparametri tramite GridSearchCV, ottimizzando primariamente la metrica della *Precision*. I modelli valutati per la loro efficacia ed efficienza sono:

- **K-Nearest Neighbors (KNN)**
- **Random Forest**
- **Support Vector Machine (SVM)**

- **Pipeline di Addestramento:** Per garantire risultati robusti, ogni modello utilizza una ImbPipeline che include:
    - **SMOTE:** Sovracampionamento nel training set per bilanciare le classi (evitando che il modello ignori la classe sbilanciata).
    - **GridSearchCV:** Ricerca automatica degli iperparametri ottimali con Cross-Validation stratificata (3-fold).

4.2 Metriche di valutazione

Andiamo adesso ad analizzare le metriche con cui sono stati valutati i modelli e i risultati ottenuti. Data la delicatezza del dominio clinico, l'obiettivo primario è stato quello di limitare i falsi positivi; per questo motivo, la metrica della **Precision** è stata scelta come indicatore principale per l'ottimizzazione degli iperparametri (tramite *GridSearchCV*). Tuttavia, per garantire una valutazione completa ed equilibrata, in fase di test sono state calcolate anche *Accuracy*, *Recall* e *F1-score*.

Per supportare l'analisi visiva delle performance, per ogni algoritmo implementato sono state prodotte tre tipologie principali di grafici:

- **ROC Curve (Receiver Operating Characteristic Curve):** Un grafico in cui l'asse delle ordinate rappresenta il tasso di veri positivi (True Positive Rate), mentre l'asse delle ascisse rappresenta il tasso di falsi positivi (False Positive Rate). Questo grafico include anche il calcolo dell'Area Sotto la Curva (AUC), fornendo una misura sintetica delle capacità discriminative del modello.
- **Precision-Recall Curve:** Questa curva rappresenta il trade-off tra la precisione e il recall del modello, risultando particolarmente informativa in contesti in cui la distribuzione delle classi può presentare sbilanciamenti. Il grafico riporta anche il valore dell'Average Precision (AP).
- **Matrice di Confusione (Heatmap):** Una visualizzazione grafica (tramite mappa di calore) che mostra il numero di previsioni corrette ed errate fatte dal modello di classificazione sul test set, esplicitando chiaramente i veri positivi (TP), falsi positivi (FP), veri negativi (TN) e falsi negativi (FN).

In aggiunta a queste valutazioni grafiche comuni a tutti i modelli, l'algoritmo **Random Forest** produce un ulteriore grafico a barre:

- **Feature Importance Bar Chart:** Questo grafico illustra le top-10 caratteristiche del dataset che hanno avuto il maggior peso decisionale, permettendo di identificare quali variabili (o combinazioni di risposte al questionario) influenzano maggiormente la diagnosi o la classificazione del modello.

Infine, anziché affidarsi unicamente a rappresentazioni visive, la stabilità e la consistenza dei risultati su diverse iterazioni sono state analizzate analiticamente mediante una rigorosa estrazione statistica dei punteggi di cross-validation. Calcolando media, varianza, deviazione standard e il Coefficiente di Variazione (CV%), è stato possibile valutare matematicamente l'affidabilità delle stime e monitorare l'eventuale presenza di *overfitting*.

4.3 K-Nearest Neighbors (KNN)

Il K-Nearest Neighbors (KNN) è un algoritmo di classificazione intuitivo che mira a determinare la classe di appartenenza di un dato di input confrontandolo con gli esempi di addestramento più simili (i "vicini"). La somiglianza viene valutata calcolando la distanza nello spazio multidimensionale delle feature.

4.3.1 Decisioni di progetto

Questo modello è stato scelto per la sua naturale semplicità concettuale e per la sua versatilità, risultando efficace su dataset di dimensioni contenute. Un punto di forza del KNN è la sua capacità di catturare relazioni non lineari complesse tra i sintomi senza presupporre a priori una specifica distribuzione dei dati clinici, basandosi esclusivamente sull'evidenza empirica dei casi pregressi (i vicini).

4.3.2 Ottimizzazione degli iperparametri (GridSearchCV)

L'obiettivo di questa fase non si è limitato alla sola esplorazione del numero di vicini (k), ma ha previsto un'ottimizzazione simultanea di tre parametri chiave:

1. Numero di vicini (n_neighbors): Valutato in un range da 1 a 20 per bilanciare la complessità del modello, evitando l'overfitting (con k troppo piccoli) o l'underfitting (con k eccessivi).
2. Pesi (weights): Per testare se fosse più efficace assegnare lo stesso peso a tutti i vicini (uniform) oppure dare maggiore importanza a quelli più prossimi al punto da classificare (distance).
3. Metrica di distanza (metric): Per valutare il miglior metodo di misurazione dello spazio (Euclidea, Manhattan o Minkowski).

L'identificazione della configurazione ottimale è stata delegata alla funzione GridSearchCV, combinata con una ***Stratified 3-Fold Cross-Validation***.La GridSearch utilizza solo il training set in modo da evitare data leakage. A differenza dell'approccio manuale (osservando un grafico dell'errore), questo metodo automatizzato e rigoroso ha identificato la combinazione di iperparametri in grado di massimizzare la metrica della Precisione, garantendo un'elevata capacità di generalizzazione sui dati non visti.

4.3.3 Addestramento e predizione

Una volta identificata la combinazione ottimale di parametri, il modello finale è stato addestrato sull'intero training set. Il modello addestrato viene valutato sul test set, che finora non è mai stato visto dal modello.

4.3.4 Valutazione Finale

- **Matrice di Confusione:** Come visibile dalla Heatmap generata dal sistema, questa tabella permette di analizzare nel dettaglio il comportamento del modello, quantificando i Veri Positivi, Veri Negativi, Falsi Positivi e Falsi Negativi. Essendo l'algoritmo ottimizzato per la *Precisione*, ci si aspetta una particolare severità del modello nel contenere il numero di Falsi Positivi rispetto ai Falsi Negativi.

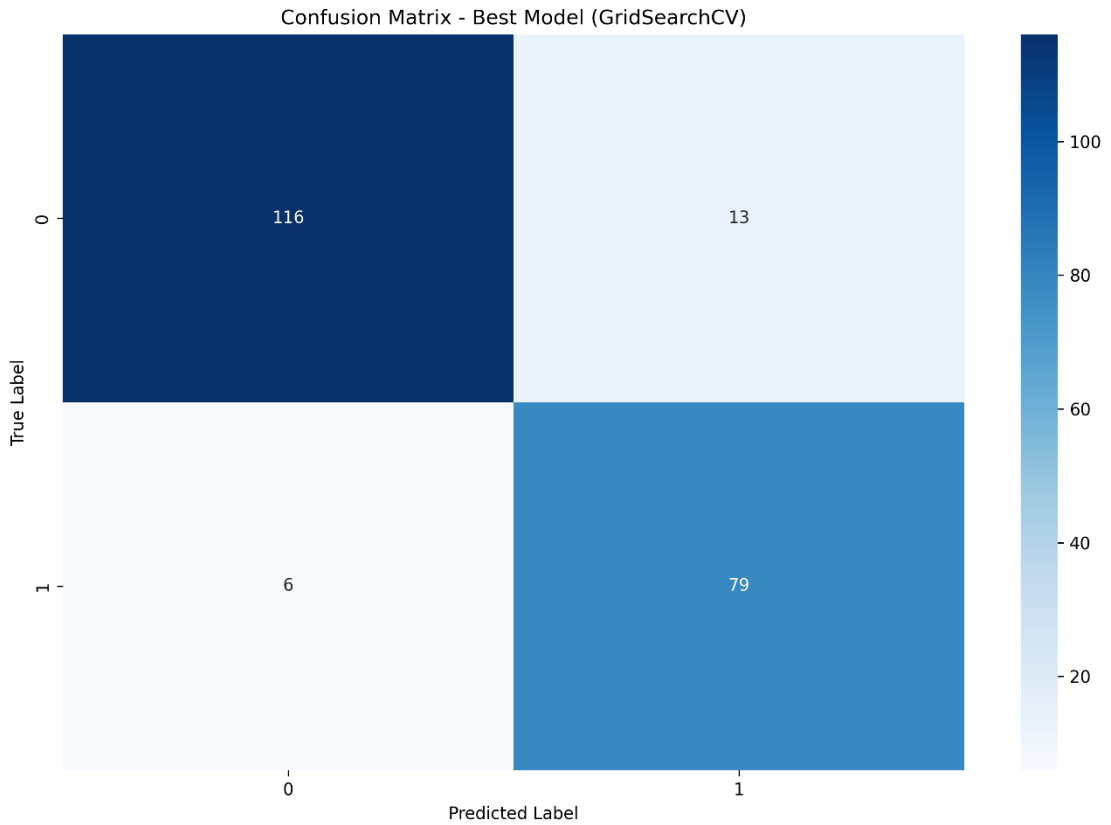

- **ROC Curve e AUC:** Il grafico della *Receiver Operating Characteristic* illustra l'andamento del tasso di veri positivi rispetto ai falsi positivi al variare delle soglie di probabilità. Il valore dell'Area Sotto la Curva (AUC) calcolato e stampato dallo script restituisce una misura sintetica dell'eccellente capacità del modello KNN di discriminare correttamente tra soggetti autistici e neurotipici.

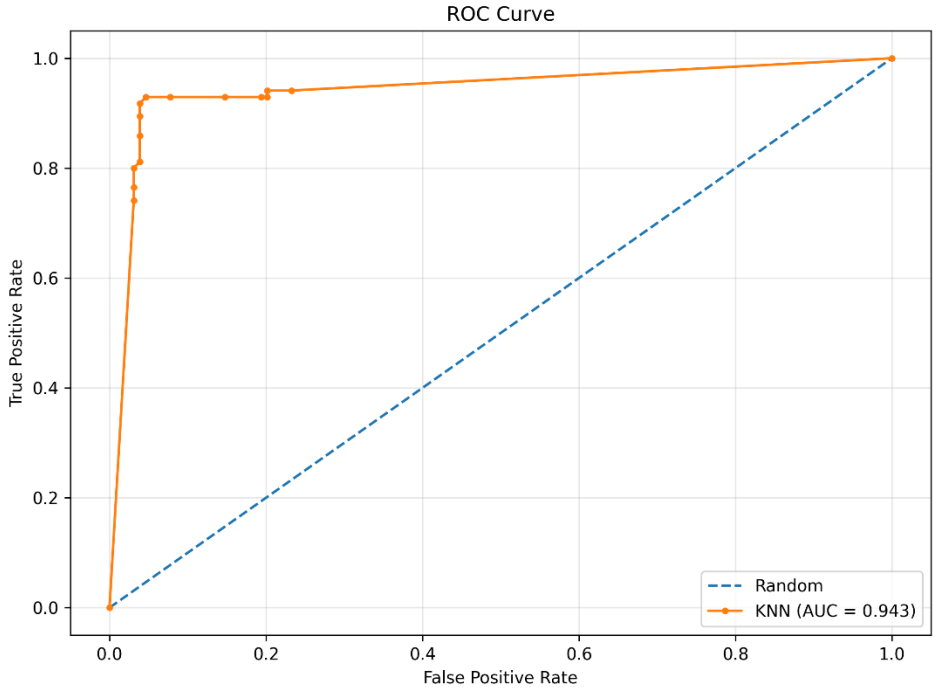

- **Precision-Recall Curve:** Questo grafico illustra il compromesso specifico tra la precisione e il recall, calcolando anche il parametro sintetico di *Average Precision (AP)*. È uno strumento cruciale in questa analisi, in quanto conferma graficamente se gli sforzi compiuti nell'ottimizzazione degli iperparametri (mirata proprio ad alzare la precisione) hanno prodotto una curva robusta in grado di mantenere bassi i tassi di falso allarme.

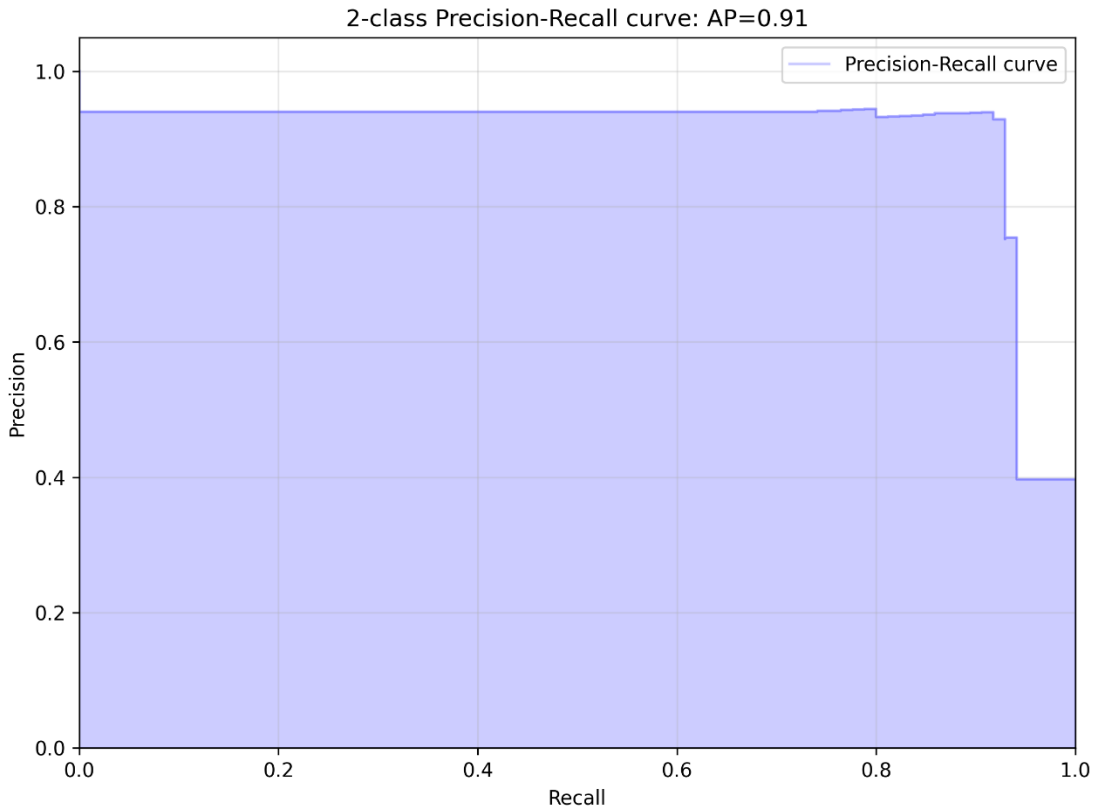

- **Analisi Statistica di Stabilità:** Oltre alle metriche visive, la stabilità e la consistenza dei risultati sono state indagate analiticamente elaborando i punteggi ottenuti durante la cross-validation. Calcolando media, varianza, deviazione standard e il Coefficiente di Variazione (CV%) sui diversi fold, è stato possibile valutare matematicamente la robustezza del modello. Un basso coefficiente di variazione certifica che le performance predittive del KNN sono coerenti e non dipendono in modo casuale dalla specifica porzione di dati fornita in fase di addestramento, indicando un'ottima generalizzazione.

4.4 Random Forest (RF) e Feature Importance

L'algoritmo Random Forest è un metodo di *Ensemble Learning* che combina le previsioni di molteplici alberi decisionali in un unico modello robusto. Sebbene un singolo albero decisionale possa essere incline all'overfitting o non perfettamente accurato, l'aggregazione di centinaia di alberi indipendenti produce previsioni medie nettamente più stabili e vicine alla realtà.

4.4.1 Decisioni di progetto

Questo modello è stato scelto per la sua eccellente precisione e stabilità intrinseca nei complessi problemi di classificazione clinica. Il Random Forest gestisce molto bene i dataset con numerose feature (sia continue che categoriche dummificate) e, grazie alla sua natura

parallelizzabile, garantisce tempi di addestramento rapidi ed efficienti. Rispetto a un singolo Decision Tree, la struttura "a foresta" attenua fisiologicamente il rischio di overfitting compensando gli errori dei singoli alberi.

4.4.2 Ottimizzazione degli iperparametri (GridSearchCV)

Invece di procedere per tentativi manuali o affidarsi a valori predefiniti arbitrari, è stata implementata una rigorosa ricerca automatizzata tramite GridSearchCV per individuare la configurazione ideale del modello. L'algoritmo ha esplorato sistematicamente diverse combinazioni per tre iperparametri cruciali:

1. **Numero di alberi (n_estimators):** Testato per valori di 100 e 200, cercando il punto di equilibrio ideale dove l'aumento delle prestazioni giustifica il maggior costo computazionale.
2. **Profondità massima (max_depth):** Valutata tra 16, 18, 20 e *None* (nessun limite). Questo parametro è vitale: se l'albero è troppo profondo memorizza i dati (overfitting), se è troppo superficiale non cattura le relazioni complesse (underfitting).
3. **Campioni minimi per foglia (min_samples_leaf):** Testato con valori da 1 a 4. Aumentare questo numero impedisce al modello di creare rami troppo specifici per singoli pazienti, forzando una maggiore generalizzazione.

Come per gli altri modelli, l'ottimizzazione è stata guidata dalla massimizzazione della **Precisione** all'interno di una validazione incrociata stratificata (fino a 3-fold), applicando contemporaneamente la tecnica SMOTE solo sui fold di addestramento. Questo processo garantisce che la combinazione scelta sia quella statisticamente più robusta per generalizzare su nuovi dati.

4.4.3 Valutazione Finale

- **Matrice di Confusione:** Analizzando la mappa di calore generata (rf_confusion_matrix.png), emerge l'eccellente capacità del modello nel limitare gli errori di classificazione. L'ottimizzazione mirata alla precisione si riflette in un contenimento rigoroso dei Falsi Positivi, confermando l'affidabilità del Random Forest nel non generare falsi allarmi diagnostici.

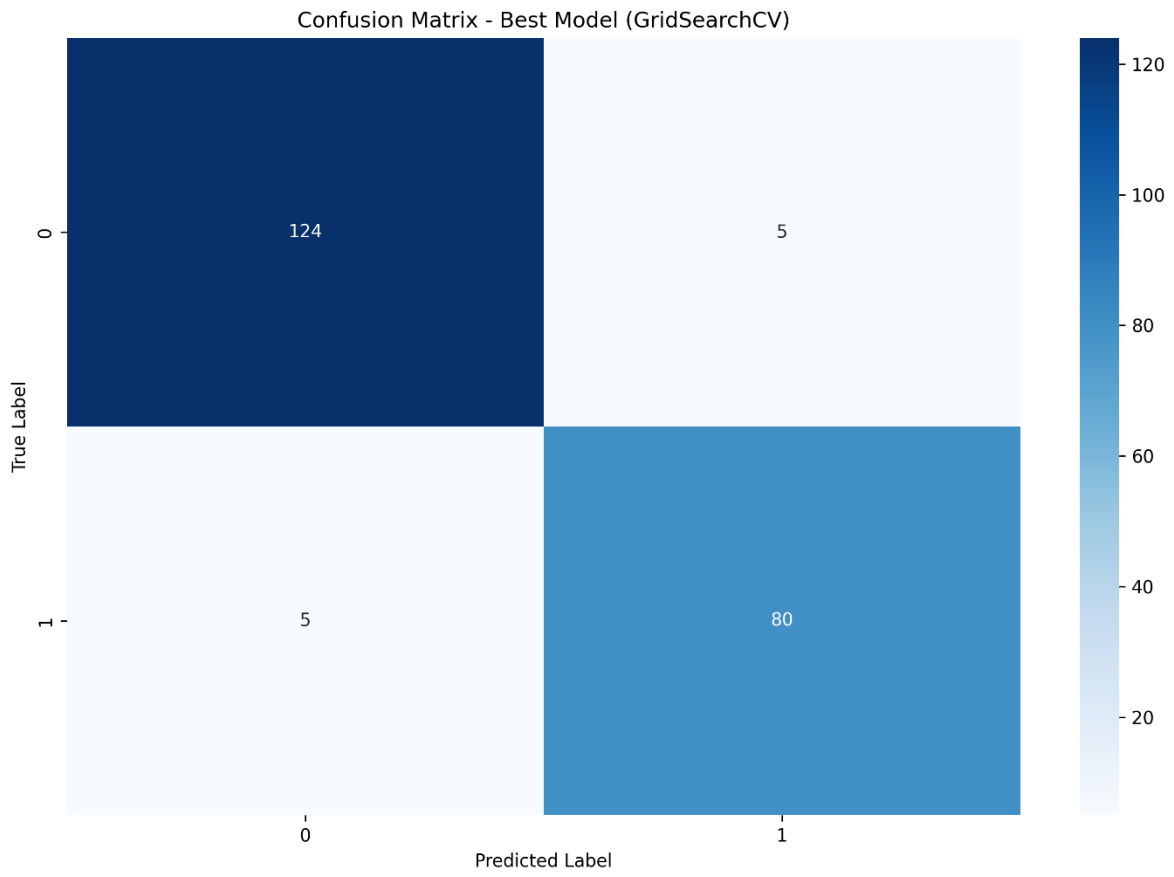

- **ROC Curve e AUC:** Il grafico della curva ROC e il calcolo dell'Area Sotto la Curva confermano una forte capacità del modello di discriminare le due classi. Un valore di AUC vicino a 1 suggerisce un'ottima separazione statistica tra i profili comportamentali dei soggetti autistici e quelli di controllo.

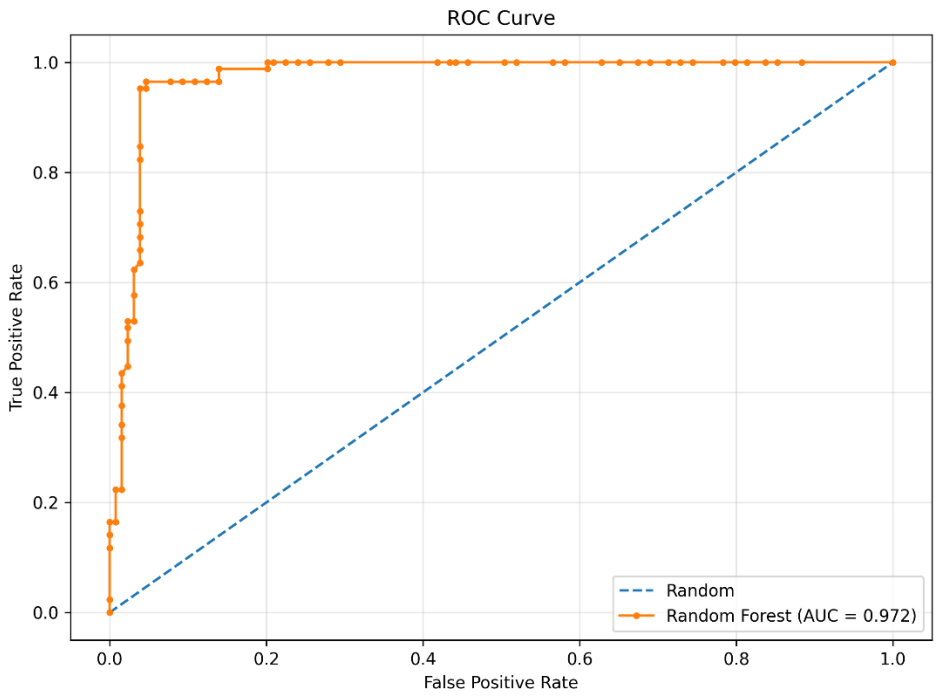

- **Precision-Recall Curve:** La curva e il conseguente valore di *Average Precision* presentano un trade-off molto bilanciato, indicando che il modello riesce a mantenere un'elevata correttezza predittiva anche quando si spinge a identificare un maggior numero di casi positivi.

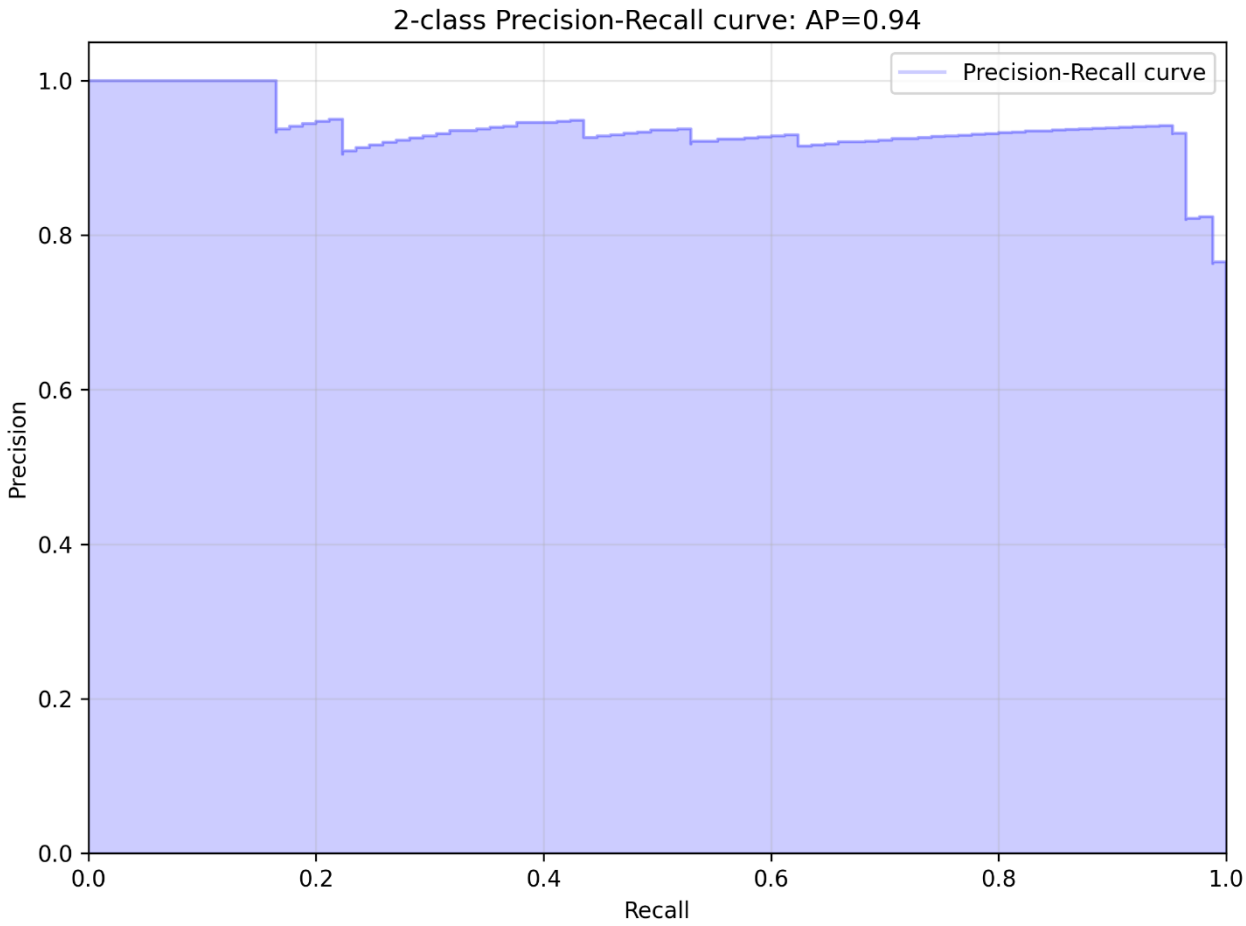

- **Analisi Statistica di Stabilità e Varianza:** L'analisi dettagliata dei punteggi di cross-validation estratta a terminale e salvata nel CSV (media, varianza, deviazione standard e coefficiente di variazione) evidenzia una notevole coerenza. La bassa deviazione standard tra i diversi fold di validazione certifica che le prestazioni del Random Forest sono stabili e indipendenti dalla specifica porzione di dati utilizzata per l'addestramento.

- **Feature Importance:** Oltre alle metriche classiche, il Random Forest ha permesso di generare un grafico a barre dedicato. Questa visualizzazione ordina in modo decrescente le top-10 caratteristiche del questionario che hanno avuto il maggior "peso" decisionale nella costruzione degli alberi, offrendo una preziosa interpretabilità clinica su quali sintomi risultino più determinanti per la classificazione automatica.

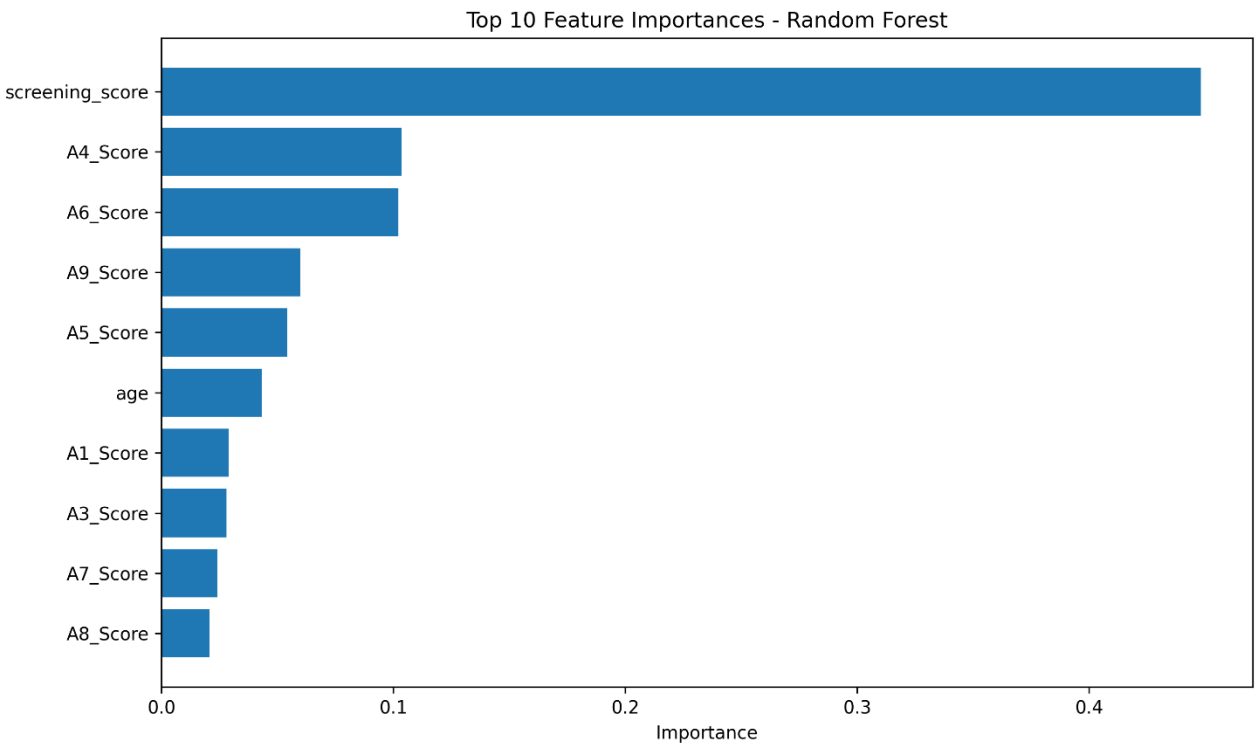

4.5 Support Vector Machine (SVM)

La Support Vector Machine (SVM) è un algoritmo di apprendimento supervisionato basato sull'idea di trovare un iperpiano (una superficie decisionale) capace di dividere al meglio un set di dati in due classi distinte. I punti del dataset più vicini a questo iperpiano, e che quindi ne definiscono la posizione e l'orientamento, sono chiamati, appunto, "Support Vectors".

4.5.1 Decisioni di progetto

Questo modello è stato selezionato in quanto strumento estremamente potente e rigoroso per la classificazione binaria. Risulta particolarmente adatto per problemi con un numero moderato di feature (come il nostro dataset dopo l'estrazione dei fattori latenti o la dummificazione) e si distingue per la sua capacità di gestire relazioni non-lineari complesse, una caratteristica cruciale quando si analizzano pattern comportamentali legati all'autismo.

4.5.2 Ottimizzazione degli iperparametri (GridSearchCV)

Al fine di estrarre le massime performance dall'algoritmo, non ci si è limitati a utilizzare parametri di default. È stata implementata una *Grid Search* combinata con *Cross-Validation stratificata* all'interno di una Pipeline (che include anche lo SMOTE) per esplorare simultaneamente tre iperparametri critici:

1. **Kernel (kernel):** È stato testato sia il kernel lineare (linear) sia il kernel Radial Basis Function (rbf). L'RBF è spesso decisivo perché proietta i dati in uno spazio a

dimensionalità superiore, permettendo all'SVM di individuare confini decisionali complessi e non lineari, impossibili da catturare con una semplice linea retta.

2. **Parametro di regolarizzazione (C):** Testato su diversi ordini di grandezza (0.1, 1, 10, 100), questo parametro controlla il compromesso tra l'ottenere un errore basso sui dati di addestramento e la massimizzazione del margine di separazione. Un valore basso crea un margine ampio (maggiore generalizzazione), mentre un valore alto cerca di classificare correttamente tutti i punti di training, aumentando il rischio di overfitting.
3. **Parametro del kernel RBF (gamma):** Valutato tra 1e-4, 1e-3 e 0.01. Questo parametro definisce l'estensione dell'influenza di un singolo Support Vector. Valori bassi significano un'influenza "lontana" e confini più morbidi, mentre valori alti rendono le decisioni molto locali, creando confini stretti attorno ai singoli punti.
   L'algoritmo ha valutato automaticamente tutte le possibili combinazioni di questi parametri, identificando e memorizzando la configurazione in grado di massimizzare la metrica di *Precisione* sui fold di validazione.

4.5.3 Valutazione Finale

- **Matrice di Confusione:** Osservando la heatmap generata dal modello (svm_confusion_matrix.png), emerge come l'SVM, una volta ottimizzato, sia in grado di effettuare classificazioni estremamente affidabili. La ricerca mirata della precisione durante la Grid Search garantisce che i casi di falsi positivi siano mantenuti rigorosamente sotto controllo.

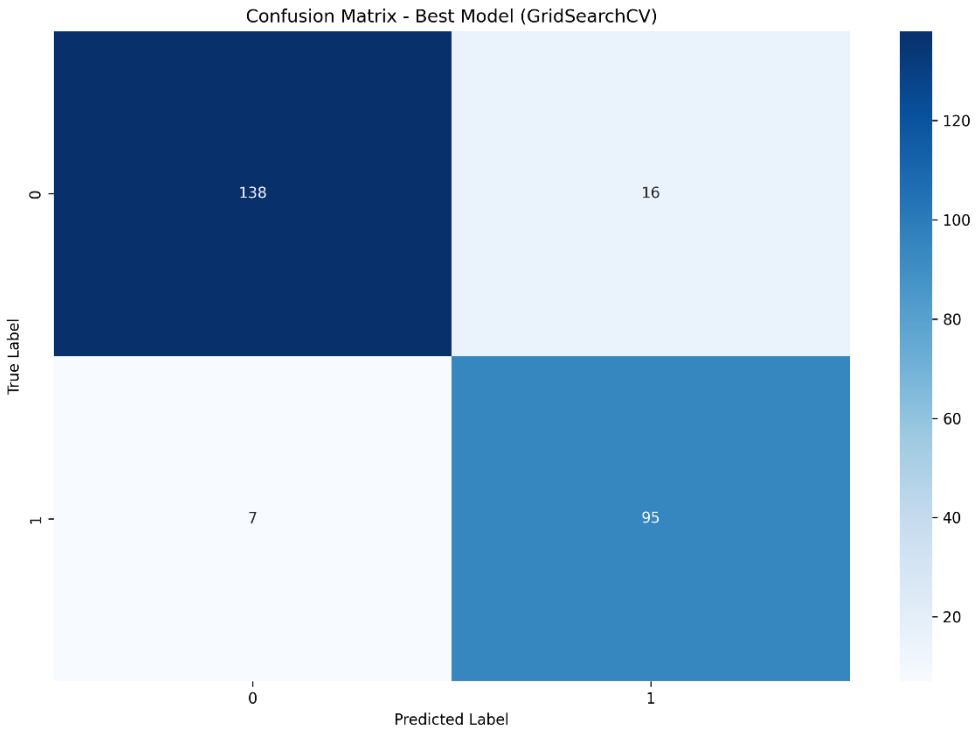

- **ROC Curve e AUC:** Il grafico ROC (svm_roc_curve.png) e il relativo valore di *Area Under the Curve* (calcolato estraendo le probabilità continue fornite dal parametro probability=True dell'SVM) dimostrano una eccellente capacità di separazione statistica tra le diagnosi positive e il gruppo di controllo.

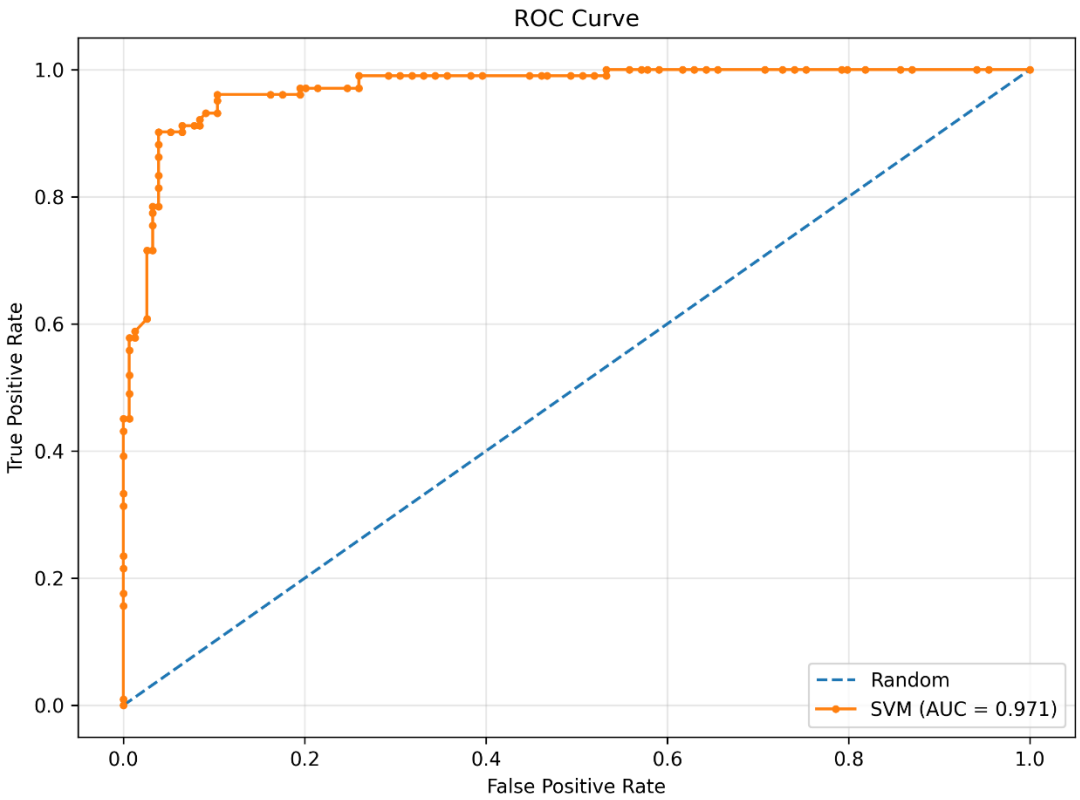

- **Precision-Recall Curve:** La curva (svm_precision_recall_curve.png) e l'elevata *Average Precision* (AP) confermano l'ottimo bilanciamento del modello. Nonostante lo sbilanciamento originario delle classi gestito tramite SMOTE, l'SVM è riuscito a identificare un confine decisionale stabile, garantendo previsioni robuste.

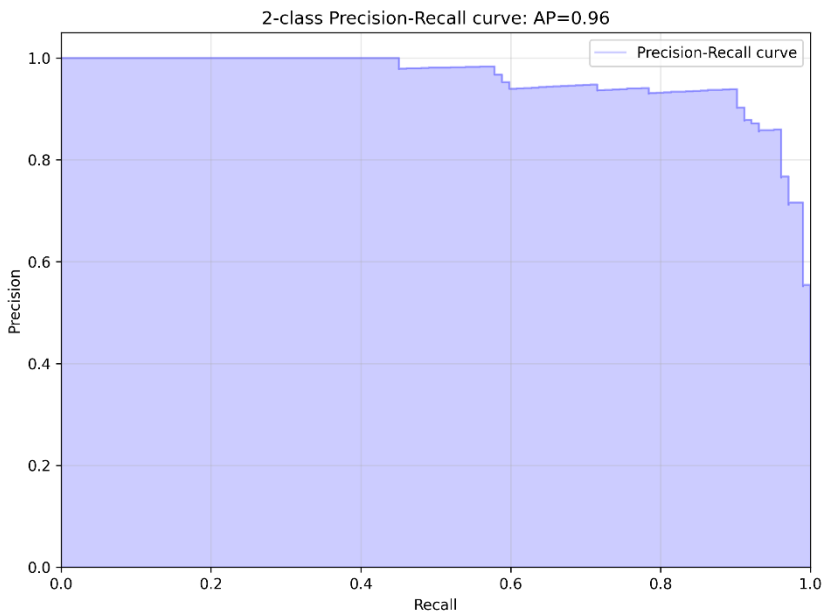

- **Analisi Statistica di Stabilità:** I log estratti durante la validazione incrociata (varianza, deviazione standard e coefficiente di variazione tra i fold) testimoniano matematicamente la consistenza del modello. Un basso coefficiente di variazione indica che le prestazioni dell'iperpiano non degradano quando viene testato su diverse porzioni del dataset, segno di un'ottima generalizzazione e di un rischio di overfitting estremamente contenuto.

5. APPRENDIMENTO NON SUPERVISIONATO (CLUSTERING)

Dopo aver esplorato i metodi di apprendimento supervisionato con il datatset originale è stato usato il clustering per generare un nuovo dataset.Il clustering può essere di due tipi:

• Clustering rigido (Hard clustering): prevede l'assegnazione statica di ciascun esempio a una classe di appartenenza.

• Clustering morbido (Soft clustering): utilizza distribuzioni di probabilità per assegnare le classi associate a ciascun esempio.

Questa tecnica è stata scelta per raggruppare le caratteristiche (features) presenti nel file 'Autism-Dataset.csv'. L'obiettivo è individuare dei cluster latenti, ovvero gruppi di variabili simili, assegnando loro dei gradi di appartenenza rispetto a centroidi calcolati in modo automatico.

L'utilizzo di questa tecnica nel progetto mira a creare un nuovo set di variabili sintetiche (i "Fattori") da sostituire alle feature numeriche originali per descrivere ciascun paziente, esportando il risultato in un nuovo file chiamato 'Autism-Dataset-factors.csv'. Questo approccio di riduzione della dimensionalità potrebbe aprire nuove prospettive sulle relazioni nascoste tra le domande del questionario, aggregando le risposte correlate in macro-fattori e contribuendo a una visione più strutturata e comprensiva dell'autismo.

In questo caso, è stata utilizzata una tecnica di Soft clustering, in particolare il Fuzzy C-Means.

5.1 Fuzzy C Means

Il Fuzzy C-Means è un algoritmo di clustering che suddivide un insieme di dati (in questo caso, la matrice delle feature trasposta) in K cluster. Introduce un **grado di appartenenza** continuo (tra 0 e 1) per ciascun elemento rispetto a ogni cluster.

L'algoritmo inizia generando casualmente una matrice di appartenenza. Successivamente, calcola la posizione dei centroidi pesando i punti in base al loro grado di appartenenza e aggiorna le probabilità in base alla distanza dai nuovi centroidi. Il processo si ripete fino a convergenza (ovvero quando la matrice non cambia più in modo significativo). L'obiettivo è minimizzare una funzione di costo basata sulle distanze pesate, creando cluster in cui le variabili possono appartenere parzialmente a più gruppi contemporaneamente.

Dato che parte delle caratteristiche nel dataset sono di natura categorica e l'algoritmo matematico accetta solo caratteristiche numeriche, è stato necessario separarle. A tal fine, lo script isola le variabili numeriche (sostituendo eventuali valori mancanti con la moda) per darle in pasto all'algoritmo, conservando intatte le variabili categoriche per concatenarle nuovamente ai fattori finali generati.

Una volta preparati i dati, ho dovuto determinare il numero ottimale di cluster (fattori). A tal scopo, abbiamo utilizzato la nota tecnica del metodo del gomito, supportata dalla libreria kneed. In questo grafico, sull'asse delle ordinate sono rappresentati i valori della funzione obiettivo del Fuzzy C-Means, mentre sull'asse delle ascisse sono rappresentati i k cluster esplorati. L'algoritmo seleziona automaticamente il punto di flesso (il gomito) per scegliere il valore ottimale.

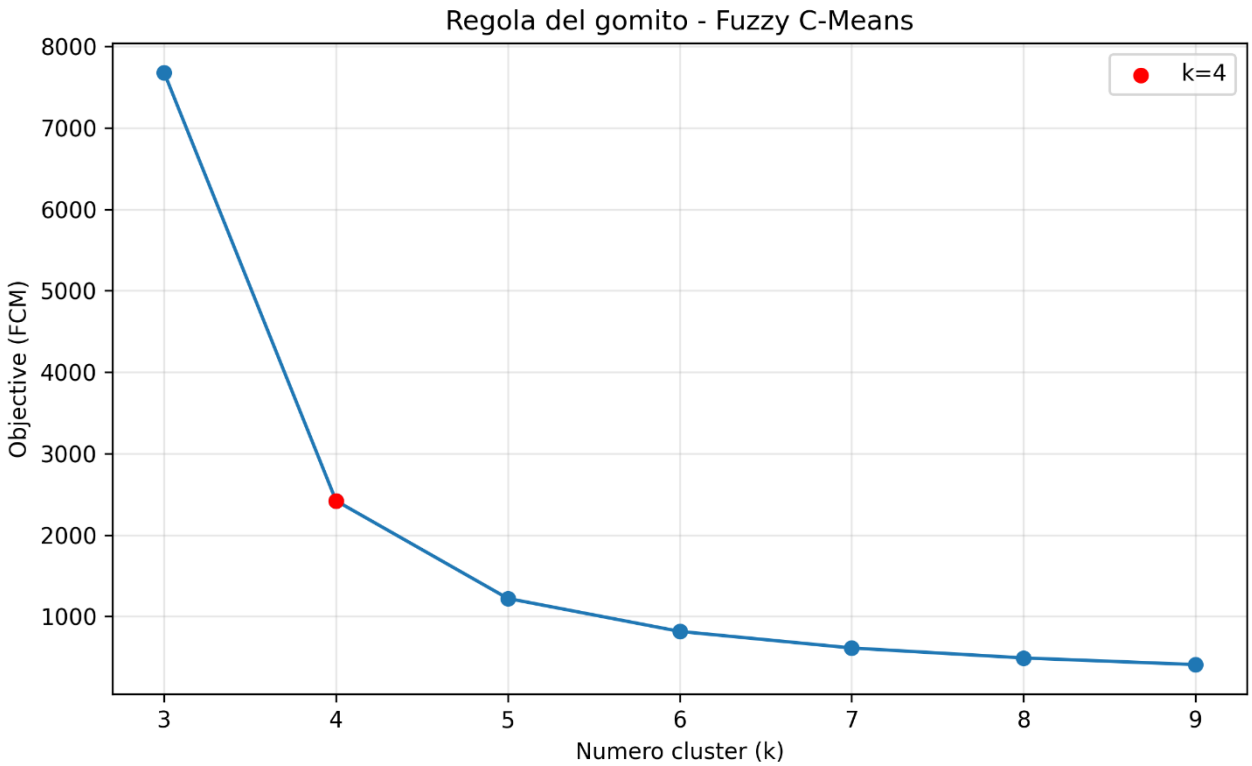

Le metriche e i parametri scelti per la configurazione del modello sono stati:

- **c_min=3 e c_max=9**: il range del numero di cluster entro cui l'algoritmo cerca la soluzione ottimale (partendo da un minimo di 3).

- **seed=42**: questo parametro controlla la riproducibilità dei risultati. Fissando un valore, il modello fornirà sempre la stessa matrice di appartenenza casuale iniziale quando viene addestrato con gli stessi dati.
- **max_iter=300 e tol=1e-5**: specificano rispettivamente il numero massimo di iterazioni consentite e la tolleranza per la convergenza. Se la differenza della matrice di appartenenza tra un'iterazione e l'altra scende sotto la soglia di 10^ {-5}, l'algoritmo si ferma, garantendo efficienza e accuratezza

6. Risultati

6.1 Dataset Originale

Modello	Accuracy	Precision	Recall	F1-score	AUC	Avg Precision
KNN	0.9112	0.8587	0.9294	0.8927	0.943	0.9057
SVM	0.9102	0.8559	0.9314	0.8920	0.971	0.9587
Random Forest	0.9533	0.9412	0.9412	0.9412	0.972	0.9384

6.2 Dataset dei Fattori

Modello	Accuracy	Precision	Recall	F1-score	AUC	Avg Precision
KNN	0.9252	0.8966	0.9176	0.9070	0.936	0.8924
SVM	0.9414	0.9065	0.9510	0.9282	0.969	0.9527
Random Forest	0.9439	0.9294	0.9294	0.9294	0.982	0.9771

7. ANALISI RISULTATI E CONCLUSIONI

L’analisi dei risultati si concentra sul confronto diretto tra le prestazioni dei modelli supervisionati sul **dataset originale** e sul **dataset trasformato tramite Fuzzy C-Means**, utilizzando esclusivamente le metriche riportate nelle due tabelle precedenti. Questo confronto permette di valutare l’efficacia dei modelli e il contributo apportato dalla riduzione delle dimensioni tramite fattori latenti.

7.1 Analisi del Dataset Originale

Nel dataset originale, composto dalle caratteristiche cliniche e comportamentali non trasformate, i tre modelli supervisionati – KNN, SVM e Random Forest – hanno mostrato prestazioni globalmente buone, ma con differenze significative in termini di stabilità e qualità predittiva.

Il **Random Forest** emerge come il modello più performante del gruppo: ottiene una *Accuracy* pari a **95,33%**, una *Precision* del **94.12%** e valori di *Recall* e *F1-score* anch'essi pari al **94.12%**. Questi risultati indicano una capacità molto elevata di distinguere correttamente tra casi positivi e negativi, mantenendo un bilanciamento ottimale tra falsi positivi e falsi negativi.

Il modello **SVM**, pur ottenendo punteggi leggermente inferiori a quelli del Random Forest, si dimostra comunque solido, con una *Precision* pari all'**85.59%** e un *Recall* del **93.14%**. Le sue prestazioni confermano che l'algoritmo riesce a individuare correttamente la maggior parte dei casi positivi, anche se presenta una precisione inferiore rispetto al Random Forest.

Il **KNN**, invece, pur raggiungendo una *Accuracy* del **91.12%,** mostra un comportamento meno stabile: la *Precision* pari all'**85.87%** e il *Recall* del **92.94%** suggeriscono una buona capacità discriminativa, ma il modello risulta più sensibile alla struttura originale ad alta dimensionalità del dataset, come evidenziato dalla nota di un potenziale overfitting.

Nel complesso, sul dataset originale il **Random Forest** si conferma il modello preferibile, grazie al suo equilibrio tra accuratezza globale, precisione e affidabilità.

7.2 Analisi del Dataset dei Fattori (Fuzzy C-Means)

Nel dataset trasformato tramite Fuzzy C-Means, composto da soli quattro fattori latenti, si osserva un miglioramento complessivo delle prestazioni per tutti i modelli, con un impatto particolarmente evidente per KNN e SVM.

Il modello **KNN** mostra il progresso più significativo: la *Precision* aumenta da **85,87%** a **89,66%**, e l'*Accuracy* passa da **91.12%** a **92.52%**. La riduzione della dimensionalità ha quindi migliorato la capacità del modello di definire correttamente i confini decisionali nello spazio delle variabili.

L'**SVM** beneficia fortemente della rappresentazione più compatta fornita dai fattori, ottenendo una *Accuracy* pari a **94,14%** e una *Precision* del **90.65%**, nettamente superiori rispetto al dataset originale. Questi risultati indicano che la separazione delle classi è più chiara e che l'algoritmo è in grado di costruire confini decisionali più efficaci.

Il **Random Forest** mantiene prestazioni molto elevate anche sui fattori, con valori stabili e un'AUC pari a **98,2%**, superiore a quella ottenuta nel dataset originale. Ciò dimostra che il

modello riesce a sfruttare pienamente la rappresentazione ridotta, mantenendo un'elevata qualità predittiva anche con meno informazioni grezze.

7.3 Conclusioni

L'analisi comparativa dei due insiemi di risultati evidenzia alcuni punti chiave:

1. La **riduzione delle dimensioni tramite Fuzzy C-Means** migliora significativamente le prestazioni dei modelli che lavorano su distanze o margini decisionali, come **KNN** e **SVM**, mostrando che i fattori latenti catturano informazioni più strutturate e discriminanti rispetto alle feature originali.
2. Il **Random Forest** si conferma il modello più affidabile in entrambi gli scenari, mantenendo una precisione molto elevata anche dopo la trasformazione del dataset. La stabilità osservata suggerisce che il modello è in grado di apprendere pattern robusti sia dallo spazio originale sia da quello ridotto.
3. Il passaggio dai dati originali ai fattori ridotti comporta **un miglioramento globale della qualità predittiva**, riducendo la complessità del dataset senza sacrificare informazione, e in alcuni casi aumentando la capacità discriminativa dei modelli.

In conclusione, l'integrazione tra modelli supervisionati e trasformazione dei dati tramite fattori latenti costituisce un approccio efficace e robusto per lo screening preliminare dell'autismo. Il sistema risultante presenta ottime prestazioni, riduce il rischio di overfitting e migliora la generalizzazione, confermandosi un candidato solido per l'impiego in contesti applicativi reali.